

Fakultet elektrotehnike, računarstva i informacijskih tehnologija Osijek

Računarstvo usluga i analiza podataka

**SEMINARSKI RAD**  
**Student Depression Prediction**

Autor: Mihael Lacković

Osijek,  
Srpanj 2026.

## SADRŽAJ:

|                                                                 |    |
|-----------------------------------------------------------------|----|
| 1. Uvod.....                                                    | 3  |
| 2. Opis problema .....                                          | 4  |
| 2.1. Korišteni podaci .....                                     | 4  |
| 2.1.1. Deskriptivna statistika .....                            | 4  |
| 2.2. Korišteni postupci strojnog učenja.....                    | 9  |
| 3. Opis programskog rješenja.....                               | 10 |
| 3.1. Model strojnog učenja.....                                 | 11 |
| 3.1.1. Predobrada i čišćenje podataka .....                     | 11 |
| 3.1.2. Podešavanje i usporedba algoritama strojnog učenja ..... | 12 |
| 3.1.3. Temeljita usporedba performansi algoritama.....          | 12 |
| 3.2. Način korištenja API-ja.....                               | 15 |
| 3.3. Klijentska aplikacija.....                                 | 19 |
| 3.4. Dodatno .....                                              | 22 |
| 4. Zaključak.....                                               | 23 |
| 5. Poveznice i literatura.....                                  | 24 |

## 1. Uvod

U ovom seminarskom radu prikazana je izrada sustava za predikciju depresije kod studenata korištenjem metoda strojnog učenja i Azure Machine Learning platforme. Projekt obrađuje problem binarne klasifikacije gdje se na temelju dostupnih akademskih, demografskih i životnih značajki pokušava predvidjeti pripadnost zapisa jednoj od dvije klase definirane u skupu podataka.

Glavni cilj rada bio je proći kroz cijeli postupak razvoja rješenja strojnog učenja, od početne analize i pripreme podataka do treniranja modela i njegove primjene kroz cloud okruženje. U radu su provedeni predobrada podataka, usporedba više algoritama strojnog učenja, odabir najboljeg modela prema evaluacijskim metrikama te implementacija rješenja koje omogućuje dohvaćanje predikcija putem REST API-ja.

Za treniranje i objavu modela korišten je Azure Machine Learning. Najbolji model registriran je pod nazivom student-depression-model-04 i dostupan je preko endpointa student-depression-endpoint u workspaceu mlw-student-depression-prediction. Kao primjer korištenja izrađena je Streamlit aplikacija koja šalje podatke prema Azure endpointu i prikazuje dobiveni rezultat. Model služi isključivo kao demonstracija primjene strojnog učenja nad zadanim skupom podataka i nije namijenjen za donošenje medicinskih zaključaka.

## 2. Opis problema

Problem predikcije depresije kod studenata pripada području nadziranog strojnog učenja nad tabličnim podacima. U podacima se za svaki zapis nalaze ulazne značajke, primjerice dob, akademski pritisak, zadovoljstvo studijem, navike spavanja, financijski stres i obiteljska povijest mentalnih bolesti. Ciljna varijabla je stupac Depression, koji poprima vrijednosti 0 i 1.

Kao osnovni pristup korištena je usporedba više klasičnih modela strojnog učenja. Budući da je dataset tabličan i sadrži kombinaciju numeričkih i kategorijskih značajki, upotrijebljeni su modeli koji dobro rade s takvom vrstom podataka: logistička regresija, stablo odluke, slučajna šuma, Gradient Boosting, SVC i XGBoost.

### 2.1. Korišteni podaci

Za projekt je korišten lokalni CSV skup podataka student\_depression\_dataset.csv. Skup je pripremljen za rad u Azure ML workspaceu, a završno treniranje izvedeno je u Azure ML okruženju. Svaki redak predstavlja jednog studenta, a ulazne značajke opisuju akademski, osobni i životni kontekst studenta.

Nakon učitavanja skup sadrži 27 901 redaka i 15 stupaca nakon uklanjanja pomoćnih identifikacijskih stupaca. U model se ne uključuju stupci id, Name, City i Profession jer ne doprinose generalizaciji modela i mogu sadržavati informacije koje nisu prikladne za predikciju u stvarnoj upotrebi.

Ciljna varijabla je Depression. Vrijednost 0 označava zapis bez označenog rizika depresije, a vrijednost 1 zapis s označenim rizikom depresije u skupu podataka.

| Skupina značajki | Značajke                                                                                                                |
|------------------|-------------------------------------------------------------------------------------------------------------------------|
| Numeričke        | Age, Academic Pressure, Work Pressure, CGPA, Study Satisfaction, Job Satisfaction, Work/Study Hours, Financial Stress   |
| Kategorijske     | Gender, Sleep Duration, Dietary Habits, Degree, Have you ever had suicidal thoughts ?, Family History of Mental Illness |
| Uklonjeni stupci | id, Name, City, Profession                                                                                              |


Tablica 2.1. Pregled korištenih značajki

#### 2.1.1. Deskriptivna statistika

| Klasa Depression | Broj zapisa | Udio   |
|------------------|-------------|--------|
| 0                | 11565       | 41,5 % |
| 1                | 16336       | 58,5 % |


Tablica 2.2. Distribucija ciljne varijable

Distribucija ciljne varijable nije potpuno uravnotežena: klasa 1 ima veći broj zapisa od klase 0, ali omjer nije ekstremno. Zbog toga nije bilo nužno uvoditi agresivno preuzorkovanje ili poduzorkovanje. Kao primarna metrika odabrana je F1-mjera jer istovremeno uzima u obzir preciznost i odziv.




*Slika 2.1. Distribucija ciljne varijable*

Kod numeričkih značajki vidljivo je da su Work Pressure i Job Satisfaction gotovo uvijek jednaki nuli. To je očekivano za skup koji je usmjeren na studente, ali je važno zabilježiti jer takve značajke vjerojatno nose manje informacija od akademskog pritiska, zadovoljstva studijem ili financijskog stresa.




*Slika 2.2. Distribucija značajke Academic Pressure*




Slika 2.3. Distribucija značajke Financial Stress

Korelacijska matrica pokazuje očekivane odnose između dijela numeričkih značajki i ciljne varijable. Depression je pozitivno povezan s Academic Pressure, Financial Stress i Work/Study Hours, dok je negativno povezan s Age i Study Satisfaction. Korelacija ne dokazuje uzročnost, ali daje dobar početni uvid u strukturu podataka.




Slika 2.4. Korelacijska matrica numeričkih značajki

Među kategorijskim značajkama posebno se ističe pitanje Have you ever had suicidal thoughts ?. Ta značajka je vrlo osjetljiva i vjerojatno snažno povezana s ciljnom varijablom. U završnom modelu je zadržana jer je dio skupa podataka i ulazne sheme.




Slika 2.5. Distribucija značajke Have you ever had suicidal thoughts ?




Slika 2.6. Najzastupljenije kategorije značajke Degree

Distribucije značajki Sleep Duration i Dietary Habits dodatno opisuju životne navike studenata u skupu. Kod spavanja se pojavljuju četiri glavne kategorije, dok je kategorija Others rijetka. Kod prehrambenih navika najzastupljenije su Unhealthy i Moderate, što je korisno uzeti u obzir pri interpretaciji modela, ali ove značajke same po sebi nisu dovoljne za zaključivanje o ciljnoj klasi.




Slika 2.7. Distribucija značajke Sleep Duration



Slika 2.8. Distribucija značajke Dietary Habits

U deskriptivnoj analizi također je provjerena značajka Work/Study Hours. Veći broj sati rada ili učenja javlja se češće pri višim vrijednostima, što je korisno promatrati u kontekstu opterećenja studenata i kasnije interpretacije modela.





Slika 2.9. Distribucija značajke Work/Study Hours

## 2.2. Korišteni postupci strojnog učenja

Korišteni postupci strojnog učenja temelje se na klasičnoj binarnoj klasifikaciji nad tabličnim podacima. Svi modeli trenirani su nad istim skupom značajki i istim train/test splitom, kako bi usporedba bila poštena. Podaci su podijeljeni na skup za treniranje i testni skup u omjeru 80:20 uz stratifikaciju prema ciljnoj varijabli.

Za numeričke značajke primijenjena je imputacija medijanom i standardizacija. Za kategorijske značajke primijenjena je imputacija najčešćom vrijednošću i One-Hot Encoding. Predobrada je dio scikit-learn Pipeline objekta, što znači da se transformacije uče samo na trening podacima i potom primjenjuju na testne podatke.

Uspoređeni su LogisticRegression, DecisionTree, RandomForest, GradientBoosting, SVC i XGBoost. Za svaki model provedeno je podešavanje hiperparametara pomoću GridSearchCV postupka s petostrukom unakrsnom validacijom. Kao primarni kriterij odabira korištena je F1-mjera.

### 3. Opis programskog rješenja


Programsko rješenje organizirano je u nekoliko jasno odvojenih dijelova: kod za predobradu i treniranje modela, Azure konfiguracija za deploy, spremljeni rezultati i Streamlit klijentska aplikacija.

Tijek rješenja u Azure ML okruženju




Slika 3.1. Tijek rješenja od datasea do klijentske aplikacije

Završni tijek rada može se sažeti na sljedeći način: skup podataka je pripremljen u CSV formatu, trening je izveden u Azure ML okruženju, najbolji model spremljen je kao model.pkl, registriran je kao Azure ML model i deployan na Managed Online Endpoint. Streamlit aplikacija šalje JSON zahtjev endpointu i prikazuje vraćenu predikciju.



Slika 3.2. Prikaz pripremljenog skupa podataka u Azure ML workspaceu



Slika 3.3. Završeni Azure ML trening job

## 3.1. Model strojnog učenja

### 3.1.1. Predobrada i čišćenje podataka

Prije treniranja uklonjeni su stupci id, Name, City i Profession. Stupci id i Name nisu prikladni za generalizaciju jer predstavljaju identifikatore, dok City i Profession nisu korišteni u završnoj shemi modela. Nakon toga numerički stupci pretvoreni su u numerički tip, a kategorijski stupci u tekstualni/object tip.

Nedostajuće numeričke vrijednosti obrađuju se imputacijom medijanom. Kategorijske vrijednosti imputiraju se najčešćom vrijednošću i zatim kodiraju One-Hot Encoding postupkom. Budući da je encoder postavljen s `handle_unknown="ignore"`, endpoint može obraditi i kategorije koje nisu viđene u treningu bez rušenja aplikacije.

```
numeric_pipeline = Pipeline([
    ("imputer", SimpleImputer(strategy="median")),
    ("scaler", StandardScaler()),
])

categorical_pipeline = Pipeline([
    ("imputer", SimpleImputer(strategy="most_frequent")),
    ("encoder", OneHotEncoder(handle_unknown="ignore")),
])
```

Programski kod 3.1. Sažetak predobrade numeričkih i kategorijskih značajki

Cijeli postupak predobrade nalazi se u datoteci `src/preprocessing.py`, a treniranje modela u `src/train.py`.

### 3.1.2. Podešavanje i usporedba algoritama strojnog učenja

Uspoređeno je više algoritama strojnog učenja. Za svaki model definiran je manji prostor hiperparametara, a najbolja kombinacija odabrana je kroz GridSearchCV. U završnom eksperimentu korištena je petostruka unakrsna validacija, a najbolji model birao se prema F1-mjeri.

| Model              | Najbolji hiperparametri                               |
|--------------------|-------------------------------------------------------|
| XGBoost            | learning_rate=0.1; max_depth=3; n_estimators=100      |
| GradientBoosting   | learning_rate=0.1; max_depth=2; n_estimators=100      |
| SVC                | C=0.5; kernel=linear                                  |
| RandomForest       | max_depth=None; min_samples_split=2; n_estimators=100 |
| LogisticRegression | C=0.1; solver=liblinear                               |
| DecisionTree       | max_depth=3; min_samples_split=2                      |


Tablica 3.1. Najbolji hiperparametri po modelu

### 3.1.3. Temeljita usporedba performansi algoritama

| Model              | Accuracy | Precision | Recall | F1     | ROC-AUC |
|--------------------|----------|-----------|--------|--------|---------|
| XGBoost            | 0,8477   | 0,8581    | 0,8865 | 0,8721 | 0,9196  |
| GradientBoosting   | 0,8470   | 0,8548    | 0,8898 | 0,8720 | 0,9189  |
| SVC                | 0,8420   | 0,8756    | 0,8510 | 0,8631 | 0,9184  |
| RandomForest       | 0,8369   | 0,8492    | 0,8773 | 0,8630 | 0,9123  |
| LogisticRegression | 0,8423   | 0,8793    | 0,8470 | 0,8628 | 0,9184  |
| DecisionTree       | 0,8111   | 0,8199    | 0,8681 | 0,8433 | 0,8735  |


Tablica 3.2. Usporedba performansi modela na testnom skupu

Najbolji rezultat ostvario je XGBoost s F1-mjerom 0,8721 i ROC-AUC vrijednošću 0,9196. GradientBoosting je postigao gotovo jednak F1 rezultat, što pokazuje da su boosting metode dobro prilagođene ovom skupu podataka. Razlika između prvog i drugog modela mala je, pa rezultat ne treba tumačiti kao veliku dominaciju jednog algoritma, nego kao vrlo blagu prednost XGBoost modela u ovom eksperimentu.




Slika 3.4. Usporedba modela prema F1-mjeri

Matrica konfuzije najboljeg modela pokazuje da je model na testnom skupu točno klasificirao 1834 primjera klase 0 i 2897 primjera klase 1. Pogrešno je označio 479 primjera kao lažno pozitivne i 371 primjer kao lažno negativne.




*Slika 3.5. Matrica konfuzije najboljeg modela*


ROC krivulja dodatno potvrđuje da model dobro razlikuje dvije klase u testnom skupu. Vrijednost  $AUC = 0,92$  pokazuje dobru separaciju, ali se rezultat dijelom može objasniti snažnim ulaznim značajkama, posebice značajkom o suicidalnim mislima.



Slika 3.6. ROC krivulja najboljeg modela



Slika 3.7. Izlazne datoteke Azure ML joba



Slika 3.8. Registrirani model u Azure ML Model Registryju

### 3.2. Način korištenja API-ja

Model je izložen kao Azure ML Managed Online Endpoint. Korišteni workspace je mlw-student-depression-prediction, naziv endpointa je student-depression-endpoint, a registrirani model je student-depression-model-04. Za deploy je korišteno prilagođeno Azure okruženje student-depression-sklearn-1-5 s Python 3.10 i kompatibilnim verzijama biblioteka potrebnih za inferenciju.

Endpoint prima HTTP POST zahtjev na /score rutu. Ulazni podaci šalju se u JSON formatu. Osnovni podržani format je objekt s ključem data, gdje se nalazi lista zapisa. Takav oblik odgovara načinu na koji Streamlit aplikacija šalje podatke.

```
{
  "data": [
    {
      "Gender": "Male",
      "Age": 22,
      "Academic Pressure": 3,
      "Work Pressure": 0,
      "CGPA": 8.0,
      "Study Satisfaction": 3,
      "Job Satisfaction": 0,
      "Sleep Duration": "'5-6 hours'",
      "Dietary Habits": "Moderate",
      "Degree": "B.Tech",
      "Have you ever had suicidal thoughts ?": "No",
      "Work/Study Hours": 6,
      "Financial Stress": 2,
      "Family History of Mental Illness": "No"
    }
  ]
}
```

Odgovor endpointa vraća predikciju, tekstualnu oznaku i procijenjenu vjerojatnost pozitivne klase. Primjer odgovora prikazan je u nastavku.

```
[
  {
    "prediction": 0,
    "label": "No depression risk",
    "probability": 0.2345
  }
]
```

*Programski kod 3.3. Primjer odgovora endpointa*

Datoteka `azure/score.py` sadrži funkcije `init()` i `run()`. Funkcija `init()` učitava `model.pkl` iz Azure model direktorija, dok `run()` parsira ulazni JSON, provjerava stupce, poziva model i formatira rezultat.

```
def run(raw_data):
    df = _parse_payload(raw_data)
    _validate_columns(df)
    predictions = model.predict(df)
    probabilities = _positive_probability(model, df)
    return [{
        "prediction": int(pred),
        "label": "Depression risk" if int(pred) == 1 else "No depression risk",
        "probability": round(float(prob), 6)
    } for pred, prob in zip(predictions, probabilities)]
```

*Programski kod 3.4. Sažetak logike inferencije u `score.py`*



etfos.hr > mlw-student-depression-prediction > Endpoints > student-depression-endpoint

## student-depression-endpoint

Details Test Consume Monitoring **PREVIEW** Logs

+ Add deployment Refresh Update traffic Delete

### Endpoint attributes

**Service ID**  
student-depression-endpoint

**Description**  
--

**Provisioning state**  
Succeeded

**Error details**  
--

**Compute type**  
Managed

**Created by**  
Mihael Lacković

**Created on**  
Jul 7, 2026 10:09 PM

**Last updated on**  
Jul 7, 2026 10:18 PM

**Authentication type**  
Key

**Public network access**  
Enabled

**Swagger URI**  
https://student-depression-endpoint.polandcentral.inference.ml.azure.com/swagger.json

**REST endpoint**  
https://student-depression-endpoint.polandcentral.inference.ml.azure.com/score

**Metrics**  
[View metrics](#)

**Tags**  
No tags

### Deployment summary

**Live traffic allocation**  
blue (100%)

**Mirrored traffic allocation**  
--

### Deployment blue

**Name**  
blue

**Live traffic**  
100%

**Scoring script**  
score.py

**Provisioning state**  
Succeeded

**Error details**  
--

**SKU**  
Standard\_DS2\_v2

**Quota type**  
Dedicated

**Egress public network access**  
Enabled

**Instance count**  
1

**Scaling**  
[Configure auto scaling](#)

**Model ID**  
student-depression-model-04:1

**Environment**  
student-depression-sklearn-1-5:1

Slika 3.9. Status Managed Online Endpointa

# student-depression-endpoint

Details **Test** Consume Monitoring PREVIEW Logs

## Sample inference

### Input \*


```
"Gender": "Male",  
"Age": 22,  
"Academic Pressure": 3,  
"Work Pressure": 0,  
"CGPA": 8.0,  
"Study Satisfaction": 3,  
"Job Satisfaction": 0,  
"Sleep Duration": "5-6 hours",  
"Dietary Habits": "Moderate",  
"Degree": "B.Tech",  
"Have you ever had suicidal thoughts ?": "No",  
"Work/Study Hours": 6,  
"Financial Stress": 2
```

Test

### jsonOutput

```
[  
  {  
    "prediction": 0,  
    "label": "No depression risk",  
    "probability": 0.159049  
  }  
]
```

Slika 3.10. Testiranje endpointa kroz Azure ML Studio



Slika 3.11. Consume tab s podacima za pristup endpointu

### 3.3. Klijentska aplikacija

Klijentska aplikacija izrađena je u Streamlitu. Aplikacija prikazuje formu za unos svih značajki koje model očekuje, šalje podatke na Azure ML endpoint i zatim prikazuje rezultat predikcije. U aplikaciji se API key unosi kroz bočni izbornik i ne sprema se u repozitorij.

Sučelje sadrži numeričke kontrole za dob, akademski pritisak, radni pritisak, CGPA, zadovoljstvo studijem, zadovoljstvo poslom, radne/studijske sate i financijski stres. Za kategorijske značajke koriste se selectbox kontrole. Time se smanjuje mogućnost slanja neispravnih vrijednosti prema endpointu.

```
headers = {
    "Authorization": f"Bearer {api_key}",
    "Content-Type": "application/json",
}
payload = {"data": [input_data]}
response = requests.post(AZURE_ENDPOINT_URL, headers=headers, json=payload)
```

Programski kod 3.5. Slanje zahtjeva iz Streamlit aplikacije

Nakon uspješnog poziva endpointa aplikacija prikazuje jednu od dvije poruke: predikciju povećanog rizika ili predikciju bez indikacije povećanog rizika. Uz to se prikazuje label koji vraća endpoint i vjerojatnost pozitivne klase.

# Student Depression Prediction

Aplikacija šalje podatke na Azure ML Managed Online Endpoint i prikazuje predikciju modela.

Ovaj model služi isključivo za demonstraciju strojnog učenja i nije medicinski dijagnostički alat.

## Ulazni podaci

|                                       |           |     |
|---------------------------------------|-----------|-----|
| Gender                                | Male      | ▼   |
| Age                                   | 22        | – + |
| Academic Pressure                     | 3         | – + |
| Work Pressure                         | 0         | – + |
| CGPA                                  | 8.00      | – + |
| Study Satisfaction                    | 3         | – + |
| Job Satisfaction                      | 0         | – + |
| Sleep Duration                        | 5-6 hours | ▼   |
| Dietary Habits                        | Moderate  | ▼   |
| Degree                                | B.Tech    | ▼   |
| Have you ever had suicidal thoughts ? | No        | ▼   |
| Work/Study Hours                      | 6         | – + |
| Financial Stress                      | 2         | – + |
| Family History of Mental Illness      | No        | ▼   |
| <button>Predict</button>              |           |     |

Slika 3.12. Streamlit forma za unos podataka

## Rezultat

Predikcija: nema indikacije povećanog rizika

Label: No depression risk

Probability: 0.1590

Interpretacija: model procjenjuje niži rizik.

Poslani JSON payload

```
{
  "data": [
    {
      "Gender": "Male"
      "Age": 22
      "Academic Pressure": 3
      "Work Pressure": 0
      "CGPA": 8
      "Study Satisfaction": 3
      "Job Satisfaction": 0
      "Sleep Duration": "5-6 hours"
      "Dietary Habits": "Moderate"
      "Degree": "B.Tech"
      "Have you ever had suicidal thoughts ?": "No"
      "Work/Study Hours": 6
      "Financial Stress": 2
      "Family History of Mental Illness": "No"
    }
  ]
}
```

Azure response

```
{
  "prediction": 0
  "label": "No depression risk"
  "probability": 0.159049
}
```

Slika 3.13. Prikaz rezultata predikcije u klijentskoj aplikaciji

### 3.4. Dodatno

Struktura projekta može se vidjeti u tablici 3.3.:

| Direktorij           | Namjena                                             |
|----------------------|-----------------------------------------------------|
| azure/               | Azure environment i score.py skripta za inferenciju |
| data/                | CSV skup podataka                                   |
| notebooks/           | EDA notebook i lokalni sanity check notebook        |
| src/                 | Predobrada, treniranje i evaluacija modela          |
| outputs/eda/         | Grafovi deskriptivne analize                        |
| outputs/local_model/ | Model, metadata, metrike i evaluacijski grafovi     |
| streamlit_app/       | Streamlit REST klijent                              |
| scripts/             | Lokalna provjera score.py skripte                   |

Tablica 3.3. Struktura projekta

Lokalna provjera score.py skripte služi za rano otkrivanje problema s formatom JSON zahtjeva i učitavanjem modela.

U repozitorij se ne sprema stvarni Azure API key. Datoteka config.example.py služi samo kao primjer konfiguracije. Potrebno je preimenovati config.example.py u config.py i dodati API key.

## 4. Zaključak

U sklopu projekta izrađeno je rješenje za klasifikaciju zapisa iz skupa podataka o depresiji kod studenata. Kroz projekt su provedeni osnovna analiza i priprema podataka, obrada numeričkih i kategorijskih značajki, treniranje više modela strojnog učenja te usporedba njihovih rezultata. Nakon evaluacije najbolji model implementiran je pomoću Azure Machine Learning platforme i izložen kroz Managed Online Endpoint.

Najbolje rezultate ostvario je XGBoost model s F1-mjerom 0,8721 i ROC-AUC vrijednošću 0,9196. Vrlo slične rezultate ostvarili su i drugi modeli, posebno GradientBoosting, što pokazuje da više različitih pristupa može uspješno prepoznati obrasce prisutne u korištenom skupu podataka. Kao konačni model odabran je XGBoost zbog najbolje ostvarene F1 vrijednosti na testnom skupu.

Važno ograničenje projekta je područje primjene samog modela. Budući da se radi o podacima povezanim s mentalnim zdravljem, rezultate nije moguće promatrati kao medicinsku procjenu. Dobivene metrike ovise o korištenom skupu podataka i značajkama koje su u njemu dostupne, među kojima postoje vrlo jaki prediktori poput akademskog pritiska, financijskog stresa i odgovora povezanih sa suicidalnim mislima. Za stvarnu primjenu bilo bi potrebno dodatno testiranje na novim podacima i uključivanje stručnjaka iz odgovarajućeg područja.

## 5. Poveznice i literatura

GitHub repozitorij:

<https://github.com/lackovicmihael/Student-Depression-Prediction>

[1] Kaggle, Depression Student Dataset,

<https://www.kaggle.com/datasets/ikynahidwin/depression-student-dataset>

[2] F. Pedregosa i sur., “Scikit-learn: Machine Learning in Python”, Journal of Machine Learning Research, 2011.

[3] Microsoft Learn, “Online endpoints for real-time inference - Azure Machine Learning”,

<https://learn.microsoft.com/azure/machine-learning/concept-endpoints-online>

[4] Streamlit documentation, <https://docs.streamlit.io/>